


Setrem

Introdução à Inteligência Artificial

João Paulo Aires

(IA)



Índice

01 → Regressão Linear

02 → Regressão Logística

01 →

Regressão Linear

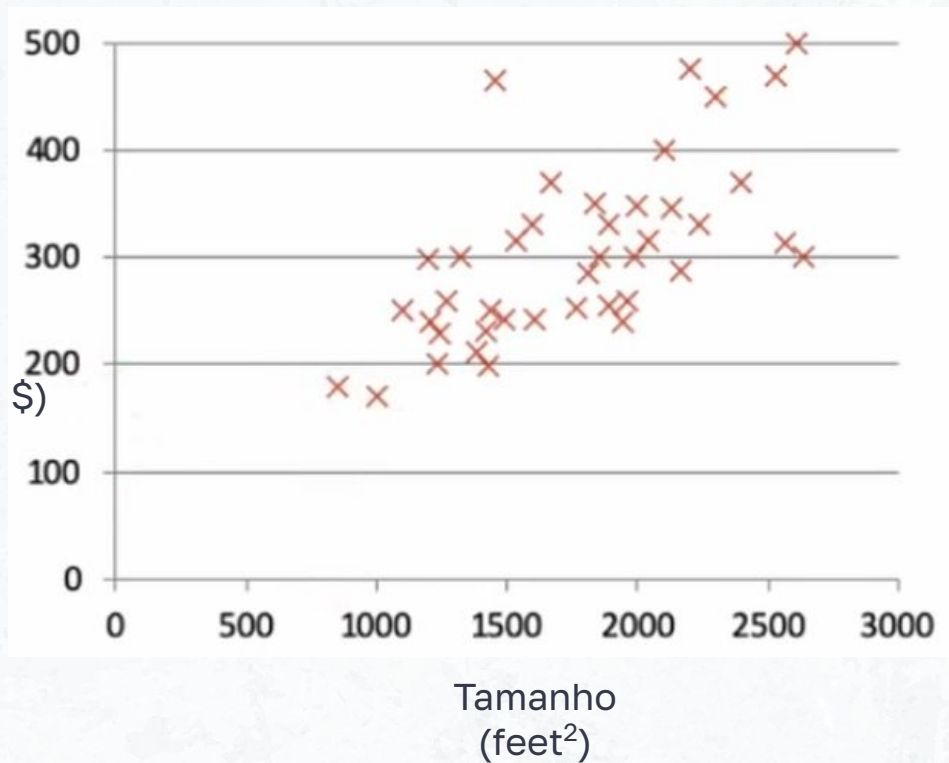
Regressão Linear

Preços de Casas (Portland)

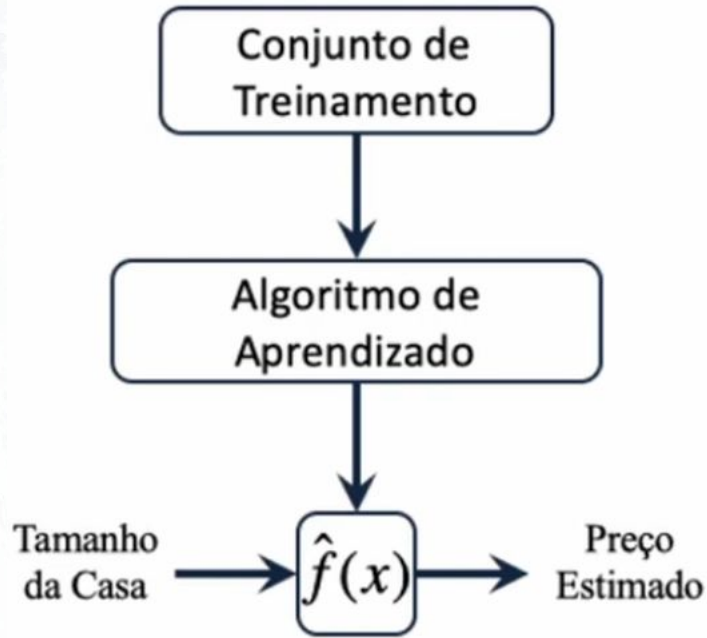
| Tamanho em feet ² (x) | Preço (\$) em milhares (f(x)) |
|-------------------------------------|----------------------------------|
| 2104 | 460 |
| 1416 | 232 |
| 1534 | 315 |
| 852 | 178 |
| ... | ... |

Preço
(em milhares \$)

Conjunto de
Treinamento



Regressão Linear




Regressão Linear Univariada

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Regressão Linear

$$\hat{f}(x) = \theta_0 + \theta_1 x$$




$$\theta_0 = 1.5$$

$$\theta_1 = 0$$

$$\boxed{\hat{f}(x) = 1.5 + 0x}$$

Regressão Linear


$$\hat{f}(x) = \theta_0 + \theta_1 x$$



$$\theta_0 = 1.5$$

$$\theta_1 = 0$$

$$\hat{f}(x) = 1.5 + 0x$$




$$\theta_0 = 0$$

$$\theta_1 = 0.5$$


$$\hat{f}(x) = 0 + 0.5x$$

Regressão Linear




$$\theta_0 = 1.5$$
$$\theta_1 = 0$$

$$\hat{f}(x) = 1.5 + 0x$$



$$\theta_0 = 0$$
$$\theta_1 = 0.5$$

$$\hat{f}(x) = 0 + 0.5x$$



$$\theta_0 = 1$$
$$\theta_1 = 0.5$$

$$\hat{f}(x) = 1 + 0.5x$$

Algoritmo Gradiente Descendente

Como minimizar $J(\theta_0, \theta_1)$?


Dada uma função de custo $J(\theta_0, \theta_1)$

Objetivo $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Algoritmo do Gradiente Descendente:

- Inicialize com algum valor para θ_0, θ_1
- Modifique incrementalmente θ_0, θ_1 para reduzir $J(\theta_0, \theta_1)$ até que possivelmente $J(\theta_0, \theta_1)$ tenha sido minimizada.

Gradiente Descendente



Gradiente Descendente

repetir até convergir {

$$\theta_0 := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

}

Gradiente Descendente

repetir até convergir {

$$\theta_0 := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

}

Atenção!
Atualização Simultânea!!

$$\text{temp0} := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$


$$\text{temp1} := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

$$\theta_0 := \text{temp0}$$


$$\theta_1 := \text{temp1}$$

Entendendo o papel da derivada

Por simplicidade, assumamos a existência de uma função de custo com apenas um parâmetro, $\theta \in \Re$, $J(\theta)$




Entendendo o papel da derivada



Por simplicidade, assumamos a existência de uma função de custo com apenas um parâmetro, $\theta \in \Re$, $J(\theta)$

$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

Entendendo o papel da derivada




Por simplicidade, assumamos a existência de uma função de custo com apenas um parâmetro, $\theta \in \Re$, $J(\theta)$

$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

$$\theta := \theta - \alpha \text{ (num positivo)}$$

Entendendo o papel da derivada




Por simplicidade, assumamos a existência de uma função de custo com apenas um parâmetro, $\theta \in \Re$, $J(\theta)$

$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

$$\theta := \theta - \alpha \text{ (num positivo)}$$

Entendendo o papel da derivada




Por simplicidade, assumamos a existência de uma função de custo com apenas um parâmetro, $\theta \in \Re$, $J(\theta)$

$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

$$\theta := \theta - \alpha \text{ (num positivo)}$$

Entendendo o papel da derivada




Por simplicidade, assumamos a existência de uma função de custo com apenas um parâmetro, $\theta \in \Re$, $J(\theta)$

$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

$$\theta := \theta - \alpha \text{ (num positivo)}$$

Entendendo o papel da derivada




Por simplicidade, assumamos a existência de uma função de custo com apenas um parâmetro, $\theta \in \Re$, $J(\theta)$

$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

$$\theta := \theta - \alpha \text{ (num negativo)}$$


Regressão Linear

$$\hat{f}(x) = \theta_0 + \theta_1 x$$




$$\begin{aligned}\theta_0 &= 1.5 \\ \theta_1 &= 0\end{aligned}$$

$$\hat{f}(x) = 1.5 + 0x$$



$$\begin{aligned}\theta_0 &= 0 \\ \theta_1 &= 0.5\end{aligned}$$


$$\hat{f}(x) = 0 + 0.5x$$



$$\begin{aligned}\theta_0 &= 1 \\ \theta_1 &= 0.5\end{aligned}$$

$$\hat{f}(x) = 1 + 0.5x$$


Regressão Linear



$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Ideia: Escolher Θ_0 e Θ_1 de forma que $f'(x)$ esteja próximo de $f(x)$ para as instâncias de treinamento $(x, f(x))$

Regressão Linear



$$\hat{f}(x) = \theta_0 + \theta_1 x$$


$$\hat{f}(x^{(i)}) - f(x^{(i)})$$

$$\frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^{(i)}) - f(x^{(i)}) \right)^2$$

$$\frac{1}{N} \sum_{i=1}^N \left((\theta_0 + \theta_1 x^{(i)}) - f(x^{(i)}) \right)^2$$

Ideia: Escolher θ_0 e θ_1 de forma que $\hat{f}(x)$ esteja próximo de $f(x)$ para as instâncias de treinamento $(x, f(x))$

Regressão Linear



$$\hat{f}(x) = \theta_0 + \theta_1 x$$

$$\hat{f}(x^{(i)}) - f(x^{(i)})$$


$$\frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^{(i)}) - f(x^{(i)}) \right)^2$$

$$\frac{1}{N} \sum_{i=1}^N \left((\theta_0 + \theta_1 x^{(i)}) - f(x^{(i)}) \right)^2$$

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left((\theta_0 + \theta_1 x^{(i)}) - f(x^{(i)}) \right)^2$$

Ideia: Escolher θ_0 e θ_1 de forma que $\hat{f}(x)$ esteja próximo de $f(x)$ para as instâncias de treinamento $(x, f(x))$

Regressão Linear



$$\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$$

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

$$\hat{f}(x^{(i)}) - f(x^{(i)})$$

$$\frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^{(i)}) - f(x^{(i)}) \right)^2$$

$$\frac{1}{N} \sum_{i=1}^N \left((\theta_0 + \theta_1 x^{(i)}) - f(x^{(i)}) \right)^2$$

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left((\theta_0 + \theta_1 x^{(i)}) - f(x^{(i)}) \right)^2$$

Ideia: Escolher θ_0 e θ_1 de forma que $\hat{f}(x)$ esteja próximo de $f(x)$ para as instâncias de treinamento $(x, f(x))$


Modelo: $\hat{f}(x) = \theta_0 + \theta_1 x$

Parâmetros: θ_0, θ_1

Função de Custo: $J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^{(i)}) - f(x^{(i)}) \right)^2$


Objetivo: $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Função de Custo J




$$f'(x)$$

(Para valores fixos de θ_0 e θ_1 ,
é uma função de x)




$$J(\theta_0, \theta_1)$$

(Função dos parâmetros θ_0, θ_1)




$$f'(x)$$

(Para valores fixos de θ_0 e θ_1 ,
é uma função de x)



$$J(\theta_0, \theta_1)$$

(Função dos parâmetros θ_0, θ_1)





$$\begin{aligned}\theta_0 &= 800 \\ \theta_1 &= -0.15\end{aligned}$$

$$f'(x)$$

(Para valores fixos de θ_0 e θ_1 ,
é uma função de x)

$$J(\theta_0, \theta_1)$$

(Função dos parâmetros θ_0, θ_1)





$$\begin{aligned}\theta_0 &= 360 \\ \theta_1 &= 0\end{aligned}$$

$$f'(x)$$

(Para valores fixos de θ_0 e θ_1 ,
é uma função de x)

$$J(\theta_0, \theta_1)$$

(Função dos parâmetros θ_0, θ_1)



$$\theta_0 = 500$$



$$\theta_1 = -0.025$$

$$f'(x)$$

(Para valores fixos de θ_0 e θ_1 ,
é uma função de x)

$$J(\theta_0, \theta_1)$$


(Função dos parâmetros θ_0, θ_1)



$$\theta_0 = 230$$

$$\theta_1 = 0.13$$

Tamanho do passo α (taxa de aprendizado)



Calculando as derivadas parciais

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^{(i)}) - f(x^{(i)}) \right)^2$$

$$\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = \frac{1}{N} \sum_{i=1}^N \hat{f}(x^{(i)}) - f(x^{(i)}) = \frac{1}{N} \sum_{i=1}^N (\theta_0 + \theta_1 x^{(i)}) - f(x^{(i)})$$

$$\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) = \frac{1}{N} \sum_{i=1}^N \left(\hat{f}(x^{(i)}) - f(x^{(i)}) \right) x^{(i)} = \frac{1}{N} \sum_{i=1}^N \left((\theta_0 + \theta_1 x^{(i)}) - f(x^{(i)}) \right) x^{(i)}$$


Gradiente Descendente

repetir até convergir {


$$\left. \begin{aligned} \theta_0 &:= \theta_0 - \alpha \frac{1}{N} \sum_{i=1}^N \left[\left(\theta_0 + \theta_1 x^{(i)} \right) - f(x^{(i)}) \right] \\ \theta_1 &:= \theta_1 - \alpha \frac{1}{N} \sum_{i=1}^N \left[\left(\left(\theta_0 + \theta_1 x^{(i)} \right) - f(x^{(i)}) \right) x^{(i)} \right] \end{aligned} \right\} \begin{array}{l} \text{Atualização} \\ \text{Simultânea} \end{array}$$

}

Gradiente Descendente



Função de Custo: Erro Quadrático Médio



Regressão Linear Univariada

Preços de Casas (Portland)

| Tamanho em feet ² (x) | Preço (\$) em milhares ($f(x)$) |
|---|--------------------------------------|
| 2104 | 460 |
| 1416 | 232 |
| 1534 | 315 |
| 852 | 178 |
| ... | ... |

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

**Conjunto de
Treinamento**

Regressão Linear Multivariada

Mas e se tivermos...

| Tamanho em feet ² (x) | # Quartos | # Andares | Anos | Preço (\$) em milhares ($f(x)$) |
|---|-----------|-----------|------|---|
| 2104 | 5 | 1 | 45 | 460 |
| 1416 | 3 | 2 | 40 | 232 |
| 1534 | 3 | 4 | 30 | 315 |
| 852 | 2 | 1 | 36 | 178 |
| ... | ... | ... | ... | ... |

Regressão Linear Multivariada

Notação

m = número de atributos
 $\mathbf{x}^{(i)}$ = i-ésima instância \rightarrow ex: $\mathbf{x}^{(3)} = \begin{bmatrix} 1534 \\ 3 \\ 4 \\ 30 \\ 315 \end{bmatrix}$

$x_j^{(i)}$ = valor do j-ésimo atributo da i-ésima instância \rightarrow ex: $x_3^{(2)} = 4$

| Tam | # Q | # A | Anos | Preço |
|------|-----|-----|------|-------|
| 2104 | 5 | 1 | 45 | 460 |
| 1416 | 3 | 2 | 40 | 232 |
| 1534 | 3 | 4 | 30 | 315 |
| 852 | 2 | 1 | 36 | 178 |
| ... | ... | ... | ... | ... |

Regressão Univariada

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

Regressão Multi-variada

$$\hat{f}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_m x_m$$

$$\hat{f}(\mathbf{x}) = \theta_0 + \sum_{i=1}^m \theta_i x_i$$

Notação Vetorial para Regressão Multi-Variada

$$\hat{f}(\mathbf{x}) = \theta_0 + \sum_{i=1}^m \theta_i x_i$$

$$x_0 = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \quad N \times 1$$

Notação Vetorial para Regressão Multi-Variada

$$\hat{f}(\mathbf{x}) = \theta_0 + \sum_{i=1}^m \theta_i x_i$$

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \quad N \times 1$$

$$\text{Logo, } \mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} \quad (m+1) \times 1$$

Notação Vetorial para Regressão Multi-Variada

$$\hat{f}(\mathbf{x}) = \theta_0 + \sum_{i=1}^m \theta_i x_i$$

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \quad N \times 1$$

$$\text{Logo, } \mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} \quad (m+1) \times 1$$

$$\Theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_m \end{bmatrix} \quad (m+1) \times 1$$

Notação Vetorial para Regressão Multi-Variada

Podemos reescrever $\hat{f}(\mathbf{x}) = \theta_0 + \sum_{i=1}^m \theta_i x_i$

como $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$

Notação Vetorial para Regressão Multi-Variada

Podemos reescrever $\hat{f}(\mathbf{x}) = \theta_0 + \sum_{i=1}^m \theta_i x_i$

como $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$

$$\Theta^T = \begin{bmatrix} \theta_0 & \theta_1 & \cdots & \theta_m \end{bmatrix} \quad \mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}$$

Gradiente Descendente para Regressão Multi-Variada

Modelo: $\hat{f}(\mathbf{x}) = \Theta^T \mathbf{x}$

Parâmetros: Θ

Função de Custo: $J(\Theta) = \frac{1}{2N} \sum_{i=1}^N \left(\Theta^T \mathbf{x}^{(i)} - f(\mathbf{x}^{(i)}) \right)^2$

Gradiente Descendente para Regressão Multi-Variada

Anteriormente ($m = 1$)

repetir até convergir {

$$\theta_0 := \theta_0 - \alpha \frac{1}{N} \sum_{i=1}^N [(\theta_0 + \theta_1 x^{(i)}) - f(x^{(i)})]$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{N} \sum_{i=1}^N [((\theta_0 + \theta_1 x^{(i)}) - f(x^{(i)})) x^{(i)}]$$

}

Novo Algoritmo ($m \geq 1$)

repetir até convergir {

$$\theta_j := \theta_j - \alpha \frac{1}{N} \sum_{i=1}^N [(\Theta^T \mathbf{x}^{(i)} - f(\mathbf{x}^{(i)})) x_j^{(i)}]$$

para ($j = 0, 1, \dots, m$)


}

Gradiente Descendente para Regressão Multi-Variada

Dicas:

- Normalizar os atributos para acelerar convergência
 - Utilizar estratégias já vistas como padronização ou transformação para intervalos $[0, 1]$ ou $[-1, 1]$
 - Garantir que o gradiente descendente esteja funcionando
 - Plotar função de custo x iteração do gradiente descendente


Gradiente Descendente para Regressão Multi-Variada




Gradiente Descendente para Regressão Multi-Variada



Gradiente Descendente para Regressão Multi-Variada



Debugando o Gradiente Descendente



- Heurística para escolha de α :
1. Começar com valores pequenos (ex: 0.001)
 2. Incrementar o valor por algum fator (ex: 3, 10, etc.) para agilizar convergência, mas sempre conferindo se os valores estão decrescendo após cada iteração

02 →

Regressão Logística

Regressão Logística

- Apesar do nome, é um algoritmo de classificação!

Regressão Logística

- Apesar do nome, é um algoritmo de classificação!
- Utilizado para discriminar entre duas classes
 - $f(x) = \{0, 1\}$

Regressão Logística

- Apesar do nome, é um algoritmo de classificação!
- Utilizado para discriminar entre duas classes
 - $f(x) = \{0, 1\}$
 - Geralmente, 0 indica ausência (classe negativa) e 1 indica presença (classe positiva) do que se deseja classificar

Regressão Logística

- Apesar do nome, é um algoritmo de classificação!
- Utilizado para discriminar entre duas classes
 - $f(x) = \{0, 1\}$
 - Geralmente, 0 indica ausência (classe negativa) e 1 indica presença (classe positiva) do que se deseja classificar
 - Ex: diagnóstico de HIV
 - 0 = sem HIV (classe negativa)
 - 1 = com HIV (classe positiva)

Regressão Logística

- Gera função $0 \leq f'(x) \leq 1$
- Em regressão linear, $f'(x) = \Theta^T \mathbf{x}$
- Qual o modelo para regressão logística?

Regressão Logística

- Gera função $0 \leq f'(x) \leq 1$
- Em regressão linear, $f'(x) = \Theta^T \mathbf{x}$
- Qual o modelo para regressão logística?
 - $f'(x) = \text{sigmoide}(\Theta^T \mathbf{x})$

Regressão Logística


- Gera função $0 \leq f'(x) \leq 1$
- Em regressão linear, $f'(x) = \Theta^T \mathbf{x}$
- Qual o modelo para regressão logística?
 - $f'(x) = \text{sigmoide}(\Theta^T \mathbf{x})$

$$\text{sigmoide}(a) = \frac{1}{1 + e^{-a}}$$

Regressão Logística

- Gera função $0 \leq f'(x) \leq 1$
- Em regressão linear, $f'(x) = \Theta^T \mathbf{x}$
- Qual o modelo para regressão logística?
 - $f'(x) = \text{sigmoide}(\Theta^T \mathbf{x})$


$$\text{sigmoide}(a) = \frac{1}{1 + e^{-a}}$$



Regressão Logística

- Gera função $0 \leq f'(x) \leq 1$
- Em regressão linear, $f'(x) = \Theta^T \mathbf{x}$
- Qual o modelo para regressão logística?
 - $f'(x) = \text{sigmoide}(\Theta^T \mathbf{x})$

$$\text{sigmoide}(a) = \frac{1}{1 + e^{-a}}$$



$$\hat{f}(\mathbf{x}) = \frac{1}{1 + e^{-(\Theta^T \mathbf{x})}}$$

Regressão Logística

- Interpretação **probabilística**
 - **Probabilidade estimada da classe positiva**

Regressão Logística

- Interpretação **probabilística**
 - **Probabilidade estimada da classe positiva**
 - Ex: classificação de tumor: $f(x) = \{\text{benigno}, \text{maligno}\}$
 - Para paciente com $f'(\mathbf{x}) = 0.7$
 - Paciente tem 70% de chance de ter tumor maligno

Regressão Logística

- Interpretação **probabilística**
 - **Probabilidade estimada da classe positiva**
 - Ex: classificação de tumor: $f(x) = \{\text{benigno, maligno}\}$
 - Para paciente com $f'(\mathbf{x}) = 0.7$
 - Paciente tem 70% de chance de ter tumor maligno

$$\hat{f}(\mathbf{x}) = p(f(\mathbf{x}) = 1 \mid \mathbf{x}; \Theta)$$

“Probabilidade que $f(\mathbf{x}) = 1$, dado \mathbf{x} parametrizado por Θ ”

Regressão Logística

- Interpretação **probabilística**
 - **Probabilidade estimada da classe positiva**
 - Ex: classificação de tumor: $f(x) = \{\text{benigno, maligno}\}$
 - Para paciente com $f'(\mathbf{x}) = 0.7$
 - Paciente tem 70% de chance de ter tumor maligno

$$\hat{f}(\mathbf{x}) = p(f(\mathbf{x}) = 1 \mid \mathbf{x}; \Theta)$$


“Probabilidade que $f(\mathbf{x}) = 1$, dado \mathbf{x} parametrizado por Θ ”

$$p(f(\mathbf{x}) = 0 \mid \mathbf{x}; \Theta) = 1 - p(f(\mathbf{x}) = 1 \mid \mathbf{x}; \Theta)$$

Regressão Logística

- Dada a interpretação probabilística da função logística, o que realmente estamos fazendo é:
 - se $\text{sigmoide}(\Theta^T \mathbf{x}) \geq 0.5$
 - então \mathbf{x} é da classe positiva
 - senão \mathbf{x} é da classe negativa

$\text{sigmoide}(\Theta^T \mathbf{x})$




$\Theta^T \mathbf{x}$

Regressão Logística

- Dada a interpretação probabilística da função logística, o que realmente estamos fazendo é:
 - se $\text{sigmoide}(\Theta^T \mathbf{x}) \geq 0.5$
 - então \mathbf{x} é da classe positiva
 - senão \mathbf{x} é da classe negativa
- O que isso nos diz a respeito de $\Theta^T \mathbf{x}$?
 - se $\Theta^T \mathbf{x} \geq 0$
 - então \mathbf{x} é da classe positiva
 - senão \mathbf{x} é da classe negativa

$\text{sigmoide}(\Theta^T \mathbf{x})$




$\Theta^T \mathbf{x}$

Regressão Logística

- Ex: Problema com dois atributos


$$\hat{f}(\mathbf{x}) = \text{sigmoide}(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$



Regressão Logística

- Ex: Problema com dois atributos

$$\hat{f}(\mathbf{x}) = \text{sigmoide}(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$




$$\Theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

Regressão Logística

- Ex: Problema com dois atributos

$$\hat{f}(\mathbf{x}) = \text{sigmoide}(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$



$$\Theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$


classe positiva: $-3 + 1x_1 + 1x_2 \geq 0$

$$x_1 + x_2 \geq 3$$

Regressão Logística

- Ex: Problema com dois atributos

$$\hat{f}(\mathbf{x}) = \text{sigmoide}(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$



$$\Theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

classe positiva: $-3 + 1x_1 + 1x_2 \geq 0$

$$x_1 + x_2 \geq 3$$

$$x_1 + x_2 = 3$$

Regressão Logística

- O problema de otimização novamente se resume a minimizar uma função de custo
- Função de custo quadrática da regressão linear pode ser usada para regressão logística?

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^{(i)}) - f(x^{(i)}) \right)^2$$

Regressão Logística

- O problema de otimização novamente se resume a minimizar uma função de custo
- Função de custo quadrática da regressão linear pode ser usada para regressão logística?

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^{(i)}) - f(x^{(i)}) \right)^2$$

Não! Pois $J(\Theta)$ vira uma função não-convexa!!
Logo possui vários ótimos locais!

Regressão Logística

- Função de custo a ser minimizada:

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\hat{f}(\mathbf{x}^{(i)}), f(\mathbf{x}^{(i)}))$$


$$\text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$

Regressão Logística

- Função de custo a ser minimizada:

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\hat{f}(\mathbf{x}^{(i)}), f(\mathbf{x}^{(i)}))$$

$$\text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$





Regressão Logística

- Função de custo a ser minimizada:

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\hat{f}(\mathbf{x}^{(i)}), f(\mathbf{x}^{(i)}))$$

$$\text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$



Regressão Logística

- Reescrevendo a função de custo:

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\hat{f}(\mathbf{x}^{(i)}), f(\mathbf{x}^{(i)}))$$

$$\text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N -f(\mathbf{x}^{(i)}) \log(\hat{f}(\mathbf{x}^{(i)})) - (1 - f(\mathbf{x}^{(i)})) \log(1 - \hat{f}(\mathbf{x}^{(i)}))$$

Regressão Logística

- Reescrevendo a função de custo:

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N \text{custo}(\hat{f}(\mathbf{x}^{(i)}), f(\mathbf{x}^{(i)}))$$

$$\text{custo}(\hat{f}(\mathbf{x}), f(\mathbf{x})) = \begin{cases} -\log(\hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 1 \\ -\log(1 - \hat{f}(\mathbf{x})) & \text{se } f(\mathbf{x}) = 0 \end{cases}$$

$$J(\Theta) = \frac{1}{N} \sum_{i=1}^N -f(\mathbf{x}^{(i)}) \log(\hat{f}(\mathbf{x}^{(i)})) - (1 - f(\mathbf{x}^{(i)})) \log(1 - \hat{f}(\mathbf{x}^{(i)}))$$

$$J(\Theta) = -\frac{1}{N} \sum_{i=1}^N f(\mathbf{x}^{(i)}) \log(\hat{f}(\mathbf{x}^{(i)})) + (1 - f(\mathbf{x}^{(i)})) \log(1 - \hat{f}(\mathbf{x}^{(i)}))$$

Regressão Logística

- Sabendo que a nova função de custo é **convexa**, como minimizá-la?
 - Gradiente Descendente!

$$J(\Theta) = -\frac{1}{N} \sum_{i=1}^N f(\mathbf{x}^{(i)}) \log(\hat{f}(\mathbf{x}^{(i)})) + (1 - f(\mathbf{x}^{(i)})) \log(1 - \hat{f}(\mathbf{x}^{(i)}))$$

Regressão Logística

- Sabendo que a nova função de custo é **convexa**, como minimizá-la?
 - Gradiente Descendente!

$$J(\Theta) = -\frac{1}{N} \sum_{i=1}^N f(\mathbf{x}^{(i)}) \log(\hat{f}(\mathbf{x}^{(i)})) + (1 - f(\mathbf{x}^{(i)})) \log(1 - \hat{f}(\mathbf{x}^{(i)}))$$

repetir até convergir {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\Theta)$$

*para (j = 0, 1, ..., m)
}*




repetir até convergir {



$$\theta_j := \theta_j - \alpha \frac{1}{N} \sum_{i=1}^N \left[\left(\hat{f}(\mathbf{x}^{(i)}) - f(\mathbf{x}^{(i)}) \right) x_j^{(i)} \right]$$

*para (j = 0, 1, ..., m)
}*

Regressão Logística





Regressão Logística





Regressão Logística


Abordagem one-vs-all



Classe 1: 


Classe 2: 

Classe 3: 




Regressão Logística

Abordagem one-vs-all




Classe 1: 
Classe 2: 
Classe 3: 



Regressão Logística

Abordagem one-vs-all



Classe 1: 
Classe 2: 
Classe 3: 